

以搭配詞操作化「人物空間」——以《紅樓夢》林黛玉為例

一、語料與問題意識

這次作業我用的是曹雪芹《紅樓夢》全文。檔案是 UTF-8 純文字，先用 OpenCC 轉成簡體，約 896,526 字，分成 35,059 句。我選的目標角色是「林黛玉」。

Woloch 說的「人物空間」，簡單講就是：一個角色在讀者心裡可以很完整，但在書裡真正分到的篇幅、描寫和詞彙其實有限。人物空間，就是「我們以為的那個人」和「敘事真正分給他的注意力」交會之後的結果。

我發現這種「有限的位置」能用統計看出來。搭配詞分析的做法是：找出那些比隨機情況更常跟著「林黛玉」出現的字。這些詞如果穩定出現，就代表敘事在寫她的時候，常常把注意力放在某些行動、關係和特質上。換句話說，搭配詞可以當成人物空間的一種側寫。

一開始我其實有點擔心紅樓夢太長、角色太多，結果會不會很空或很雜。後來表跑出來後，前面幾個詞大致符合平常讀這本書的印象，我才比較放心繼續分析。

二、資料處理流程

整個流程依照作業要求，大概分四步。

第一步，用 OpenCC 的 t2s 把全文轉成簡體。jieba 對簡體切分比較穩，所以先轉再分詞。轉完後看到約 89 萬字，才比較有「這是在處理整本書」的感覺。

第二步，用 qhchina 的 create_segmenter，backend 選 jieba，strategy 選 sentence，也就是先分句再分詞。同時設 min_word_length=2，並用 load_stopwords("zh_sim") 去掉停用詞，避免「的」「了」「著」這類詞占滿結果。分詞時 jieba 有建立 cache，最後顯示 35,059 句。

第三步，把分好的句子列表丟進 find_collocates，讓它算每個詞跟「林黛玉」的共現是否顯著。我第一次參數寫成 text=，結果報錯；改成 sentences 和 target_words 之後才跑通。這讓我更清楚：這個函數要的是已經分好詞的句子，不是生文本。

第四步，為了比較不同設定，我跑了三次：

1. window, horizon=5
2. window, horizon=10
3. sentence(同一句裡共現，不設 horizon)

結果分別存成 collocates_window5.csv、collocates_window10.csv、collocates_sentence.csv，並做成 output/results.html 方便對照。三次跑完後，終端機依序顯示 488、615、913 行，視窗愈大詞愈多，和預期一致。

三、方法與統計設置

find_collocates 的基本想法是列聯表。對「林黛玉」和某一個候選詞，看它們一起出現多少次、各自單獨出現多少次，再算出「如果只是隨機共現，期望值該是多少」。接著用 Fisher 精確檢定看差異夠不夠大。

我設 alternative="greater"，意思是只保留「一起出現得比預期多」的詞，也就是互相吸引的搭配，不管互相排斥的情況。max_p=0.05，所以表上留下的詞，p 值都小於 0.05。min_word_length=2，則是為了聚焦雙字以上的字。

視窗大小會影響我們看到的「人物空間」有多近。horizon=5 比較看得到緊鄰的動作和反應；horizon=10 會多帶一點周圍的人物和場景；sentence 則是整句一起算，比較容易看到對話和情節層級的聯繫。三種都跑，是不想只靠一種距離就下結論。

四、主要結果

三種設定下，顯著搭配詞 ($p < 0.05$) 數量分別為：window5 共 488 個、window10 共 615 個、sentence 共 913 個。視窗擴大或改以整句為單位，納入的共現詞增多，符合預期。以 horizon=5 為例，與「林黛玉」共現最強、且統計上最顯著的詞包括：

搭配詞	觀察共現 (obs)	期望共現 (exp)	比值 (ratio)	p 值
宝玉	59	27.07	2.18	< 0.001
说道	18	6.96	2.58	< 0.001
宝钗	13	4.21	3.09	< 0.001
只见	13	5.65	2.30	0.005
心里	13	2.92	4.45	< 0.001
听见	11	4.90	2.25	0.011

丫頭	10	3.68	2.72	0.004
不覺	9	1.10	8.15	< 0.001
回頭	9	0.82	10.98	< 0.001
這話	8	2.26	3.54	0.002
一聲	8	1.90	4.22	< 0.001
冷笑	8	0.89	8.98	< 0.001
說話	7	2.46	2.85	0.013
薛寶釵	6	0.21	29.03	< 0.001

看 window5 的表,「寶玉」排在最前面,實際共現 59 次,遠高於期望值。這和讀紅樓夢的經驗很接近:寫黛玉時,敘事注意力很難離開寶玉。接著「寶釵」「薛寶釵」也很醒目,尤其「薛寶釵」的比值大約 29 倍,比我預期中更明顯。

這些詞大概可以分成幾類:

1. 核心人物關係:「寶玉」「寶釵／薛寶釵」出現頻率與顯著度都高,說明敘事寫林黛玉時,注意力很常落在她和賈寶玉、薛寶釵的關係上。
2. 感知與內心:「心里」「听见」「不覺」「回頭」顯示她常被寫成正在想、正在聽、正在轉頭反應的人,而不只是被別人描述的對象。
3. 話語與表情:「说道」「這話」「說話」「冷笑」「一聲」顯示她很常出現在對話裡,而且「冷笑」這種神態也反覆出現。
4. 社會位置:「丫頭」把她放回賈府的生活場景裡。

horizon=10 和 sentence 會多出一些場景詞和次要人物,但上述幾類在三種設定中大致穩定,比較不像某個參數剛好造成的巧合,而是敘事圍繞「林黛玉」反覆分配注意力的結果。

五、詮釋:搭配詞作為人物空間的操作化

照 Woloch 的講法,人物空間是「我們感覺中的完整人物」和「書裡真正分給他的注意力」交會的地方。上面的表,其實就是注意力被分到哪裡的痕跡。

林黛玉並沒有整本小說都在寫她一人，但跟她名字一起高頻出現的詞很集中：宝玉、宝钗、心里、冷笑、说道。讀者會覺得她「有內心」「有性情」，一部分原因就是這些詞在有限篇幅裡一直重複出現，把同一組關係和特質加固了。我跑完數據再回看這些詞，比較有一種「平常讀到的印象，也可以被共現結構撐住」的感覺。

最明顯的是「宝玉」和「薛宝钗」。前者共現次數很高，後者的比值特別高。這很直觀地說明：林黛玉的位置，很大程度是在和宝玉、宝钗的對照裡被寫出來的。她不是孤立存在的人物，而是被放在「寶黛」「釵黛」結構裡的人物。這也呼應 Woloch 說的，一個人的完整性，常常建立在和許多人之間的分配關係上。

「心里」「不觉」「回头」「冷笑」則比較像在補她的主體性。篇幅有限，敘事就用感知和微表情，讓她看起來一直有反應、有態度。所以搭配詞不只告訴我們「她常和誰一起出現」，也告訴我們「敘事常用什麼方式讓她顯得有內心」。

六、方法限制與反思

換視窗、換目標詞、換書，結果都會變。horizon 從 5 改到 10，或改成 sentence，詞的數量和排序都不同；如果改查「黛玉」或「寶玉」，對照會更清楚。如果語料換成現代小說，分詞和停用詞的影響也會不一樣。也就是說，這套方法本身會參與「人物空間」長什麼樣子，不是完全中立的測量。

我在操作時最直接的感受是：參數一改，表就變；所以不能把任何一張表當成「林黛玉的真相」，只能當成某一個觀察距離下的側影。另外，搭配詞處理不了敘事不可靠、自由間接引語、角色沉默，以及「有提到但幾乎沒描寫」的情況。Woloch 很重視「一個人」和「許多人」在篇幅上的張力，但共現統計對「沒寫出來的部分」幾乎沒辦法。

即使如此，搭配詞還是提供了一個可以重複、可以比較的方式，把「注意力分給了誰」落到具體的詞上。就林黛玉來說，它呈現出的是一個很常被放在情感關係、內心反應和對話表情裡的語言位置。這大概就是敘事為她劃出的、有限但很密集的人物空間。

七、結論

這次我用《紅樓夢》全文，在三種共現設定下找出和「林黛玉」顯著搭配的詞，試著把 Woloch 的人物空間變成可以操作的分析。結果顯示：這些字詞確實能勾勒出她的關係網絡、內在描寫和對話位置，也就是敘事把注意力分給她的方式。

但同時，目標字怎麼寫、視窗多大、分詞準不準，都會改變結果。所以統計方法既在揭示人物空間，也在重新塑造我們所看到的人物空間。搭配詞可以追蹤一部分人物空間，沒辦法窮盡它。計算方法和文學理論最好互相質問，而不是互相取代。